

第 2 周：评分器安装、调用与统一输出

详细实验 runbook：偏好、情绪、一致性、结构和 OCR 评分器。

总目标：把候选图变成可比较数据行

第 2 周的输出不是漂亮图片，而是 CSV 分数。每个 scorer 都必须具备：输入 CSV、输出 CSV、错误不崩溃、可批处理。

模块	优先级	第一版策略
Preference	最高	ImageReward 必跑，HPSv2 或 PickScore 至少跑一个。
Emotion	高	EmotionCLIP 优先；不顺则 CLIP zero-shot 情绪词。
Subject	高	CLIP/DINO 参考相似度先跑。
Structure	高	GenEval 优先；不顺则人工 structure_pass 模板。
Text	中	EasyOCR 或 PaddleOCR；第一版只做 exact/contains。
Memory	中	LaMem/MemNet 可能 Caffe 旧环境，第一版可先记录或用 proxy。

Step 1 - 统一输入 CSV

```
candidate_id,prompt,image_path,reference_image,task_type,expected_text
smoke_001,a friendly taxi driver
  mascot,outputs/candidates/smoke_001.png,data/references/ref_driver.png,subject,
smoke_002,a red cube to the left of a blue sphere,outputs/candidates/smoke_002.png,,spatial,
smoke_003,a sign that says LOCAL,outputs/candidates/smoke_003.png,,text,LOCAL
```

验收：所有 scorer 都读取这个 CSV，不允许每个脚本用自己的输入格式。

Step 2 - ImageReward 偏好评分器

作用：作为人群偏好 baseline。注意它不是个人记忆激活，不应该单独决定最终输出。

```
pip install image-reward
python - <<'PY'
import ImageReward as RM
model = RM.load('ImageReward-v1.0')
print('loaded ImageReward')
PY

python scripts/scorers/score_preference_imagereward.py \
--input_csv data/pilot/week2_sample_images.csv \
--output_csv outputs/scores/imagereward_scores.csv

# 结果检查
python - <<'PY'
import pandas as pd
df=pd.read_csv('outputs/scores/imagereward_scores.csv')
print(df[['candidate_id','imagereward','error']].head())
PY
```

常见错误：模型下载慢，先确认 HF 缓存目录；图片不存在，检查 image_path；显存不足，ImageReward 可先 CPU 跑小批量。

Step 3 - HPSv2 或 PickScore 二级偏好评分器

作用：防止单一偏好模型偏差。第一版只需跑通一个。

```
# HPSv2
git clone https://github.com/tgxs002/HPSv2 resources/repos/HPSv2
# 按 README 安装；如果包安装失败，记录错误，转用 PickScore。
```

```
# PickScore
# 使用模型 yuvalkirstain/PickScore_v1
# 输入：prompt + image
# 输出：score 或 similarity
```

验收：同一批图片至少有两个偏好分数中的一个。后续报告要比较 ImageReward 与 HPS/PickScore 是否排序一致。

Step 4 - EmotionCLIP / CLIP zero-shot 情绪评分

作用：估计候选图触发的情绪倾向。它只是感知激活的一层，不等同用户真实记忆。

```
# 优先：EmotionCLIP
git clone https://github.com/Xeaver/EmotionCLIP resources/repos/EmotionCLIP
# 参考 README 下载权重或使用 Hugging Face EmotionCLIP。
```

```
# fallback：CLIP zero-shot 情绪词
python scripts/scorers/score_emotion_zeroshot_clip.py \
  --input_csv data/pilot/week2_sample_images.csv \
  --output_csv outputs/scores/emotion_scores.csv
```

验收：输出 emotion_top1 和 emotion_conf。后续可以把情绪词和用户自由联想词比较。

Step 5 - Subject consistency 初版

作用：一致性门控。第一版用 reference/candidate 的 CLIP 余弦相似度；后续可接 DreamBench++、DINO、ArcFace、IP-Adapter 等。

```
python scripts/scorers/score_subject_clip.py \
--input_csv data/pilot/week2_sample_images.csv \
--output_csv outputs/scores/subject_scores.csv
```

阈值不要一开始定死。先看分布：

```
python - <<'PY'
import pandas as pd
df=pd.read_csv('outputs/scores/subject_scores.csv')
print(df['subject_clip_sim'].describe())
PY
```

验收：有 reference 的任务必须输出 subject_clip_sim；没有 reference 的任务写 no reference，不算错误。

Step 6 - Structure / OCR / Relation

正式结构评估用 GenEval 和 T2I-CompBench；关系图可以尝试 RelTR。第 2 周先保证 pipeline 不被复杂依赖卡死。

```
# GenEval
git clone https://github.com/djghosh13/geneval resources/repos/geneval
# 按 README 安装 detector 和依赖
# 先跑官方 demo，不要立刻全量评测。
```

```
# OCR 简化版
python - <<'PY'
import easyocr
reader = easyocr.Reader(['en'], gpu=False)
print('easyocr ready')
PY
```

人工临时模板：如果 GenEval 没装通，用 structure_manual_template.csv 先填 structure_pass，保证 Week3 流水线能继续。

Step 7 - 合并分数并做质量检查

```
python scripts/scorers/merge_scores.py \
--inputs outputs/scores/imagereward_scores.csv outputs/scores/emotion_scores.csv
outputs/scores/subject_scores.csv \
--output outputs/scores/week2_all_scores.csv
```

```
python - <<'PY'
import pandas as pd
df=pd.read_csv('outputs/scores/week2_all_scores.csv')
print(df.columns.tolist())
print(df.head())
print('rows',len(df))
PY
```

检查	通过标准
行数	合并后行数等于候选图数或合理 outer merge。
错误列	所有 missing image 都写 error，而不是脚本崩溃。
分数范围	记录 min/max，不要求统一归一化。
报告	reports/week2_scorer_report.md 写明每个 scorer 状态。