

第3周：候选生成、门控与排序 Pipeline

详细实验 runbook：生成候选图、构造 baseline、完成 PCA-B0 排序。

总目标：从评分器变成完整实验

第3周要跑一个端到端小实验：任务表 -> 候选生成 -> 多评分 -> 一致性门控 -> 感知激活排序 -> baseline 对比。

Step 1 - 建 50 条任务，不要更多

每条任务必须写出不变量、允许变化、禁止丢失。否则无法判断“ 偏离是否更好 ”。

类型	数量	例子	门控重点
subject	10	friendly taxi driver mascot with reference	subject/value retention
spatial	10	red cube left of blue sphere	position relation
count/color	10	exactly five red apples	count/color
text	10	sign says LOCAL	OCR exact match
culture/emotion	10	warm family kitchen in Southeast Asia	culture/emotion fit

Step 2 - 生成 Raw candidates

每条任务 4 seeds。不要只生成 1 张，否则无法区分搜索失败和结构失败。

```
python scripts/generate_sdxl_candidates.py \  
--tasks_csv pilot_data/tasks_v0_1.csv \  
--out_dir outputs/candidates/raw \  
--num_seeds 4 \  
--steps 30 \  
--guidance 7.0
```

验收：outputs/candidates/raw/metadata.csv 中每条候选有 task_id、candidate_id、seed、image_path、seconds。

Step 3 - 创建 rewrite baseline

Prompt rewrite 只能改善表达，不能加入 layout、bbox、参考图 embedding。它是语言层 baseline，不是结构补维。

rewrite rules:

1. Keep all objects, quantities, relations and required text.
2. Add clarity terms only.
3. Do not introduce bounding boxes or coordinates.
4. Save original_prompt and rewrite_prompt.

Example:

base: a red cube to the left of a blue sphere

rewrite: a clear simple composition showing one red cube clearly on the left side and one blue sphere clearly on the right side, no extra objects

Step 4 - Matched / Mismatched augmentation

这是科学对照的核心。不能只证明“加模块有效”，必须证明“匹配失败类型的补维才有效”。

任务	Matched	Mismatched
subject	reference similarity rerank / IP-Adapter candidates	OCR text rerank
spatial	layout / relation checker	emotion-only rerank
count	detector count filter	style rewrite
text	OCR exact-match filter	subject similarity
culture	GeoDE/DollarStreet context check	generic preference only

Step 5 - 合并 Week2 scorers 跑全候选

所有候选图都进入评分器。输出 all_scores.csv。

```
python scripts/scorers/score_preference_imagereward.py --input_csv
  outputs/candidates/raw/metadata.csv --output_csv outputs/scores/raw_imagereward.csv
python scripts/scorers/score_emotion_zeroshot_clip.py --input_csv
  outputs/candidates/raw/metadata.csv --output_csv outputs/scores/raw_emotion.csv
python scripts/scorers/score_subject_clip.py --input_csv outputs/candidates/raw/metadata.csv
  --output_csv outputs/scores/raw_subject.csv
python scripts/scorers/merge_scores.py --inputs outputs/scores/raw_imagereward.csv
  outputs/scores/raw_emotion.csv outputs/scores/raw_subject.csv --output
  outputs/scores/week3_all_scores.csv
```

Step 6 - Gate + Rank

```
python scripts/pca_b0_pipeline.py \  
--scores_csv outputs/scores/week3_all_scores.csv \  
--output_csv outputs/ranked/pca_b0_ranked.csv \  
--subject_thr 0.25
```

```
python - <<'PY'  
import pandas as pd  
df=pd.read_csv('outputs/ranked/pca_b0_ranked.csv')  
print(df.groupby('task_id').head(1)[['task_id','candidate_id','accepted_by_gate','activation_rank_score']])  
PY
```

阈值调试：subject_thr 第一轮不要拿来追求最好结果，只用来排除明显崩坏。报告必须写明阈值是 pilot 手动阈值。

Step 7 - 对比四个 baseline

方法	选图规则	要暴露的问题
Raw	每个 task 取第一个 seed	最低基线
Preference-only	取 ImageReward/HPS 最高	好看但可能丢主体/结构
Consistency-only	取 subject/structure 最高	像但可能无激活感
PCA-B0	先 gate, 再 rank	核心不丢, 同时优化激活

验收：reports/week3_pipeline_report.md 至少放 5 个案例，解释为什么某张图被 gate 拒绝，为什么某张图被 rank 选中。