

第 4 周：人类小样本验证与激活词标注

详细实验 runbook：接触表、标注表、用户选择和指标。

总目标：用人类判断校验 baseline

自动指标只是代理。第 4 周用小样本人类评估回答：PCA-B0 是否比 preference-only 和 consistency-only 更接近用户判断？

Step 1 - 选择任务和候选图

从 Week3 选 20-30 个任务。每个任务准备 4

张图：Raw、Preference-only、Consistency-only、PCA-B0。四张图要随机打乱顺序。

annotation_item_id,task_id,option_A_path,option_B_path,option_C_path,option_D_path,method_A,method_B,method_C,method_D,display_order_seed

ANN001,T001,outputs/contact/T001_A.png,outputs/contact/T001_B.png,outputs/contact/T001_C.png,outputs/contact/T001_D.png,pca_b0,raw,preference_only,consistency_only,4

Step 2 - 标注说明：给用户看的原文

你将看到一个任务说明、一个参考图（如果有）和四个候选结果。

请不要猜测哪张是 AI 哪张是 baseline。只根据你的感受选择。

问题 1：整体最喜欢哪张？

问题 2：哪张最保留参考中你觉得好的部分？

问题 3：哪张偏离参考但偏离是可接受的？

问题 4：哪张丢掉了你最不希望丢掉的东西？

问题 5：你看到最喜欢的一张想到了什么？写 3-8 个词。

问题 6：为什么选择它？写一句话。

Step 3 - 制作 contact sheets

每题把四张候选拼成一张 2x2 图，标 A/B/C/D。标注者不需要打开四个文件。

```
python scripts/make_contact_sheets.py \  
--ranked_csv outputs/ranked/pca_b0_ranked.csv \  
--out_dir outputs/contact_sheets
```

人工检查 5 张 contact sheet，确认 A/B/C/D 清楚、图片没有错位。

Step 4 - 收集标注

规模	要求
最低	5 人 × 20 题 = 100 条选择
较稳	10 人 × 30 题 = 300 条选择
单人时长	不超过 20 分钟
记录	匿名 user_id、annotation_item_id、选择、理由、激活词

如果用户提供私人参考图，不要放入公开仓库。只保留匿名 ID 和派生分数。

Step 5 - 计算人类指标

```
python scripts/compute_human_metrics.py \
--annotations_csv pilot_data/human_annotations.csv \
--key_csv pilot_data/annotation_key.csv \
--output_csv outputs/human_metrics.csv
```

指标	解释
User Win Rate	整体最喜欢该方法的比例
Core Value Retention	认为该方法最保留核心价值的比例
Core Loss Rate	认为该方法丢掉禁失项的比例
Acceptable Deviation Rate	认为该方法偏离但可接受的比例

Step 6 - 激活词分析

用户写的“想到什么”是本项目最关键的定性数据。不要只统计 win rate。

activation_word categories:

- emotion: warm, lonely, exciting, calm
- memory: childhood, school, taxi, old street
- culture: local, urban, festival, family
- identity: friendly, heroic, cute, professional
- visual: round, soft, bright, rough

输出 activation_words.csv:

annotation_item_id,user_id,chosen_method,word,category

Step 7 - Week4 报告必须回答的问题

问题	报告写法
PCA-B0 是否更常被选？	给 win rate 和置信区间；不要夸大。
偏好模型是否丢核心？	列出 preference-only failure 案例。
一致性模型是否无激活？	列出 consistency-only failure 案例。
用户激活词是否支持理论？	展示 10 个代表性词和选择理由。
哪些任务失败？	按 subject/spatial/text/culture 分类。