

第 5 周：分析、消融、报告与论文雏形

详细实验 runbook：从 pilot 到可交付科研报告。

总目标：把 pilot 变成可交付科研材料

第 5 周不是继续跑更多图，而是清算：哪些脚本可复现，哪些结果可信，哪些只是 pilot，下一阶段怎么扩展。

Step 1 - 汇总所有文件

```
reports/final_5week_report.md
reports/week1_report.md
reports/week2_scorer_report.md
reports/week3_pipeline_report.md
reports/week4_human_eval_report.md
resource_matrix.csv
pca_b0_schema.json
outputs/ranked/pca_b0_ranked.csv
outputs/human_metrics.csv
pilot_data/human_annotations.csv
```

验收：别人只看这些文件，就能知道你做了什么、怎么跑、结果在哪里。

Step 2 - 画三张核心表

表	内容
Table 1 Resources	六类数据/代码/权重/用途/风险
Table 2 Methods	Raw、Preference-only、Consistency-only、PCA-B0 的差异
Table 3 Human Metrics	win/retention/loss/deviation rate

```
python scripts/make_tables.py \
--resource_matrix resource_matrix.csv \
--human_metrics outputs/human_metrics.csv \
--out_dir reports/tables
```

Step 3 - 统计不要过度

样本小，用描述统计和 bootstrap CI。不要写显著性夸张结论。

```
from bootstrap_ci import bootstrap_mean_ci
mean, lo, hi = bootstrap_mean_ci([1,0,1,1,0])
print(mean, lo, hi)
```

报告句式：在 pilot 样本中，PCA-B0 的用户选择率高于 X，但样本规模有限，结论仅作为后续实验依据。

Step 4 - 失败案例库

失败类型	至少收集
Preference-only failure	3 个：好看但丢主体/结构/文字
Consistency-only failure	3 个：一致但用户不喜欢/无激活
Emotion-overfit	3 个：情绪强但任务错
Culture mismatch	3 个：视觉合理但地域语境错
Evaluator failure	3 个：自动分高但用户反对

Step 5 - 消融实验设计

Week5 不一定全跑消融，但必须把下一轮消融写清楚。

消融	目的
No Gate	证明只用偏好/情绪会丢核心一致性
No Activation	证明只用一致性会无聊
No Emotion	测试情绪项贡献
No Culture	测试地域语境项贡献
Random Weights	测试不是任意加权都有效

Step 6 - 论文 0 框架

Title: Perceptual-Consistency Activation Baseline for Reference-Guided AIGC Evaluation

1. Introduction
2. Related Work
 - 2.1 Human preference models
 - 2.2 Affective image understanding
 - 2.3 Memorability
 - 2.4 Subject and structure consistency
 - 2.5 Culture/geographic evaluation
3. Problem Definition
4. PCA-B0 Baseline
5. Pilot Protocol
6. Results
7. Failure Analysis
8. Limitations and Future Work

Step 7 - 复现与开源前检查

检查项	要求
许可证	不要把受限数据打包进仓库，只放下载说明。
随机种子	候选图 metadata 必须保存 seed。
模型版本	HF model_id 和 revision 记录。
人工标注	匿名化 user_id，不公开私人参考图。
脚本	所有表格能从 CSV 重新生成。
报告	明确哪些是 pilot，哪些是未完成。

Step 8 - 下一 10 周路线

周次	目标
6-7	扩展到 200-500 tasks, 稳定 scorer 缓存。
8-9	用 pairwise 数据学习 rank 权重。
10-11	加入 IP-Adapter/PhotoMaker 作为 reference-guided generation baseline。
12-13	做文化/地域 subset 和个体偏好 subset。
14-15	论文 0 完整初稿和仓库整理。