

PCA-B0 总纲：感知激活-一致性基线的指导层

指导层 / 宪法层 / 判断层 · v1.0 · 2026-05-23

总命题：先保住用户最不想失去的核心不变量，再在合格候选中选择最能激活用户感知、记忆、情绪和偏好的输出。

本文件用于统领 Week 1-5 实验 runbook：任务层和行动层必须服从本指导层。

PCA-B0 总纲：感知激活-一致性基线的指导层

版本：v1.0

用途：统领 5 周实验包的“指导层 / 宪法层 / 判断层”。

一句话：先保住用户最不想失去的核心不变量，再在合格候选中选择最能激活用户感知、记忆、情绪和偏好的输出。

0. 为什么需要总纲

前面的 5 周 runbook 已经解决了“任务层”和“行动层”：每周做什么、怎么装环境、怎么跑 scorer、怎么做人类标注、怎么写报告。

但它们缺一个更高层的问题：

所有这些动作到底服从什么共同意志？

本总纲回答的不是“怎么跑脚本”，而是：

1. 我们到底在研究什么；
2. 什么算好输出；
3. 什么算失败；
4. 指标和人类判断冲突时听谁；
5. 一致性、偏好、情绪、记忆、文化之间如何排序；
6. 每周实验如何回到总问题，而不是散成工具堆。

1. 总命题

当前 AIGC 常把目标写成：图像更真实、更美、更像参考、更符合 prompt。

本项目改写目标：

AIGC 输出不是照片本身，而是可被用户感知并激活其记忆、情绪、审美和意义联想的显示信号。

因此我们不以“照片真实度”为最终目标，也不以“参考图像素相似度”为最终目标，而以：

\[

$$\text{Good Output} = \text{Core Consistency Gate} + \text{Perceptual Activation Ranking}$$

\]

换成中文：

先过核心一致性门槛，再做感知激活排序。

2. 三层目标

2.1 第一层：显像层

输出必须能被当前硬件、屏幕、投影或显示设备承载。

这意味着“图像”只是可显示信号的一种，不必局限于照片。未来它可以是图像、视频、shader、3D、点云、光场、AR 或别的可感知信号。

第一阶段为了可实验，先落在文生图 / 参考图生成上。

2.2 第二层：一致性层

用户给参考图，通常不是要求机械复制，而是说：

这里面有我已经认可的核心价值，请不要丢掉。

所以参考图不是复制模板，而是价值锚点。

一致性不是“所有东西都不变”，而是：

用户最不希望失去的核心不变量没有丢。

这些核心不变量可能是：主体身份、轮廓、亲切感、城市烟火气、文化符号、空间关系、数量、文字、构图节奏、情绪氛围。

2.3 第三层：激活层

通过一致性门控后，才比较哪张图更能激活用户。

激活不是情绪标签本身，而是：

图像在用户脑中激活了什么记忆、审美、文化经验、意义联想。

第一阶段只能用公开数据近似：情绪、记忆性、人群偏好、文化语境。个人记忆层需要小规模用户自采数据补上。

3. 核心公式

3.1 输入

每个任务写作：

\[

$T = (p, r, u, c, l, V, C, K)$

\]

其中：

- $\backslash(p\backslash)$ ：prompt / 用户语言意图；
- $\backslash(r\backslash)$ ：reference / 参考图或参考主体；
- $\backslash(u\backslash)$ ：user / 用户偏好与历史；
- $\backslash(c\backslash)$ ：context / 文化、地域、使用场景；
- $\backslash(l\backslash)$ ：invariants / 必须保持的不变量；
- $\backslash(V\backslash)$ ：variants / 允许变化的变量；
- $\backslash(C\backslash)$ ：constraints / 任务约束；
- $\backslash(K\backslash)$ ：budget / 成本预算。

3.2 一致性门控

\[

$\text{Accept}(y) = 1 [C_{\text{subject}}(y,r) \wedge C_{\text{structure}}(y,p) \wedge C_{\text{forbidden-loss}}(y,u)]$

\]

候选 $\backslash(y\backslash)$ 只有先通过核心一致性门控，才允许进入后续排序。

3.3 感知激活排序

\[

$\text{Rank}(y) = \alpha R_{\text{pref}}(y) + \beta R_{\text{emotion}}(y) + \gamma R_{\text{memory}}(y) + \delta R_{\text{culture}}(y,c)$

\]

第一版权重可以手动设定，不急着训练：

- $\backslash(\alpha\backslash)$ ：人群偏好；
- $\backslash(\beta\backslash)$ ：情绪/氛围激活；
- $\backslash(\gamma\backslash)$ ：记忆性；
- $\backslash(\delta\backslash)$ ：文化/地域适配。

3.4 最终输出

\[

$y^* = \arg\max_y \{y \in \{y: \text{Accept}(y)=1\}\} \text{Rank}(y)$

\]

如果没有候选通过门控，不强行输出“最漂亮”的错误图，而是记录失败类型。

4. 十二条指导原则

原则 1：参考图不是模板，而是价值锚点

不能把参考图简单理解为“要复制的像素”。参考图代表用户已经确认过的好东西。

原则 2：一致性是门槛，不是终点

一致性用于防止核心价值丢失；通过门槛后，允许创造性偏离。

原则 3：偏离不一定是错

如果偏离保留了核心价值，而且用户认为更好，则该偏离是可接受甚至有益的。

原则 4：感知激活高于照片真实

照片真实只是历史阶段的稳定输出形式。真正目标是用户脑中的意义激活。

原则 5：指标是证据，不是裁判

CLIP、ImageReward、EmotionCLIP、MemNet、GenEval 都只是观察工具。最终必须用人类小样本验证指标是否可信。

原则 6：残差不是失败定义

失败不是分数低，而是在给定不变量、允许变化和当前可调手段下，系统不能生成满足约束的输出。

原则 7：不可吸收是相对概念

不可吸收相对于模型、可调手段、成本预算和约束成立。换一个系统或加一个结构变量，失败可能被吸收。

原则 8：先分型，再修复

不要一失败就加模块。先判断是搜索失败、表示缺失、耦合缺失、任务欠定还是约束冲突。

原则 9：文化不是装饰，而是背景变量

同一个视觉符号在不同地域、收入、生活经验中可能激活不同意义。因此文化/地域数据不是锦上添花，而是背景建模的一部分。

原则 10：数据集服务于定义，不反过来支配定义

不要因为某个数据集有现成标签，就把问题改成它能测的东西。先保持理论定义，再选择或改造数据。

原则 11：每个实验都必须能失败

如果结果无论如何都能解释为成功，这不是科研。每个实验要写清楚什么结果会削弱我们的主张。

原则 12：保持局部、条件性、可验证

不宣称“所有 AIGC 失败都来自阻碍”，不宣称“PCA-B0 是最终审美模型”，不宣称“自动理解个人记忆”。

5. 核心概念字典

概念	定义	在实验中的表现
显示信号	用户可看到/感知的输出载体	图像、视频、3D、shader，第一阶段为图像
参考图	用户偏好与主体结构的联合锚点	reference image
核心不变量	用户最不希望失去的东西	identity、shape、关系、情绪、文化符号
允许变化	用户允许系统重构的部分	姿态、背景、风格、服装、构图
核心损失	生成结果丢掉用户最在意的部分	core-loss / forbidden-loss
感知激活	输出在用户脑中触发的情绪、记忆、联想	emotion、memorability、activation words
一致性门控	先剔除核心不变量崩坏的首选	Accept(y)
激活排序	在合格候选里选择最能触发目标感知的输出	Rank(y)
可吸收失败	可通过补充变量/介入方式修复的失败	retry、rewrite、layout、reference、verifier
不可吸收失败	当前系统和预算下无法修复的失败	任务冲突、底座能力不足、缺关键证据

6. 指导层如何统领 5 周任务

Week 1：资源清算

指导问题：这些资源分别支持总纲里的哪一层？

- EmoSet / ArtEmis：情绪与意义解释；
- LaMem / MemNet：记忆性；
- ImageReward / PickScore / HPS：人群偏好；
- DreamBench++ / VBench：主体一致性；
- T2I-CompBench / GenEval / RelTR：结构关系；
- GeoDE / Dollar Street / DIG-In：文化地域背景。

Week 1 的成果不是“下载很多资源”，而是完成资源到理论层的映射表。

Week 2: 跑通评分器

指导问题：每个 scorer 对应的是门控还是排序？

- 门控：主体、结构、禁止损失；
- 排序：偏好、情绪、记忆、文化。

严禁把排序分数拿来覆盖门控失败。例如，一张图再好看，只要主体核心崩了，就不能进入激活排序。

Week 3: 搭 pipeline

指导问题：pipeline 是否体现了“先门控，后排序”？

必须对比：

- preference-only；
- consistency-only；
- PCA-B0 gate + rank。

要证明旧 baseline 为什么不够：只偏好会丢核心，只一致会无激活。

Week 4: 做人类小样本

指导问题：我们的自动分数是否真的接近用户判断？

必须问用户：

1. 哪张更喜欢？
2. 哪张保住了参考里最好的部分？
3. 哪张偏离是可接受的？
4. 哪张丢掉了最不能丢的东西？
5. 它让你想到什么？

Week 5: 写报告

指导问题：结果支持还是削弱总纲？

必须诚实写：

- 哪些 scorer 不可靠；
- 哪些任务 PCA-B0 不比普通偏好强；
- 哪些一致性门槛太硬；
- 个人记忆层仍缺什么数据。

7. 决策规则

7.1 当“偏好分数高”但“主体一致性低”

判定：不合格。
理由：核心价值先于激活排序。

7.2 当“主体一致性高”但“用户不喜欢”

判定：通过门控但排序失败。
处理：保留为 consistency-only 失败案例，说明一致性不是终点。

7.3 当“自动指标高”但“用户拒绝”

判定：指标失真。
处理：将样本加入 evaluator failure set，检查文化、个人偏好、参考理解是否缺失。

7.4 当“偏离参考”但“用户更喜欢”

判定：可能是成功。
前提：核心不变量没有丢，用户确认偏离可接受。

7.5 当“所有候选都不过门控”

判定：候选生成能力不足或任务约束太强。
处理：进入失败吸收阶梯：retry、rewrite、matched augmentation、oracle。

7.6 当“人类也无法判断”

判定：任务欠定或约束冲突。
处理：请求补充说明，不强行输出。

8. 失败分型

类型	定义	例子	下一步
F1 任务欠定	用户没给足核心不变量	same cat 但无参考	请求补充 / 多解输出
F2 不变量错误	系统不知道什么该变	锁死全部像素导致僵硬	分离 invariant / variant
F3 表示缺失	任务变量不在表示中	数量、空间关系错	加 object slot / relation graph
F4 耦合缺失	有变量但没进生成过程	scene graph 只进 prompt	layout / attention / denoising coupling

类型	定义	例子	下一步
F5 搜索失败	解存在但没采到	多 seed 可成功	retry / rerank
F6 约束冲突	任务本身不可满足	两只猫但三只围圈	暴露冲突
F7 底座能力不足	oracle 也失败	完美 layout 仍画不出	换模型 / 训练 / adapter

9. 实验验收标准

9.1 最小成功

在 50-100 条 pilot task 中，PCA-B0 至少展示：

1. 比 preference-only 更少 core-loss；
2. 比 consistency-only 更高 human win-rate；
3. 能识别至少两类 evaluator failure；
4. 能形成可复现数据表。

9.2 强成功

在两个以上任务类型中：

$$\begin{aligned} & \left[\begin{aligned} & \text{HumanWin}(\text{PCA-B0}) > \text{HumanWin}(\text{Preference-only}) \\ & \text{CoreLoss}(\text{PCA-B0}) < \text{CoreLoss}(\text{Preference-only}) \end{aligned} \right] \end{aligned}$$

9.3 失败条件

以下任意情况都必须诚实写入报告：

- PCA-B0 不优于 preference-only；
- 一致性门控过滤掉了用户喜欢的创造性输出；
- 情绪/记忆分数和用户激活词不相关；
- 文化/地域模块没有解释力；
- 自动 evaluator 与人类判断严重冲突。

10. 数据表总规范

每个候选输出必须记录：

```
task_id
prompt
reference_image
user_preference_statement
core_value_tags
forbidden_loss
allowed_deviation
candidate_id
model_id
seed
intervention_level
intervention_type
subject_score
structure_score
forbidden_loss_flag
accept_gate
preference_score
emotion_score
memory_score
culture_score
rank_score
human_choice
human_reason
activation_words
failure_type
notes
```

没有这张表，实验就会散成“跑了一堆图”。

11. 风险边界

11.1 不做事

- 不从零训练生成模型；
- 不宣称自动理解个人记忆；
- 不宣称 PCA-B0 是审美真理；
- 不用一个总分覆盖所有维度；
- 不把参考相似度等同于用户满意；
- 不把情绪标签等同于感知激活。

11.2 必须谨慎表达的事

- “感知激活”第一版只是代理测量；
- “个人记忆”只能通过小样本用户数据近似；
- “文化适配”第一阶段只能用公开地域数据粗略支持；
- “一致性”必须按任务定义，而不是统一固定阈值。

12. 总纲放在项目里的位置

本总纲是最高层文档。

文档层级如下：

1. **指导层**：本总纲，决定原则和判断顺序；
2. **任务层**：5周 runbook，决定每周做什么；
3. **行动层**：脚本、命令、数据表，决定怎么执行；
4. **证据层**：输出、评分、人类标注，决定结果是否成立；
5. **写作层**：pilot report 和 paper outline，决定如何发表。

任何行动层变化都必须回到指导层检查：

它是否服务于“先核心一致性，后感知激活”？

如果不是，暂时不做。

13. 挂在墙上的一句话

我们不是让图像更像照片，而是让输出更准确地保留用户认可的核心价值，并激活用户真正想要的感知经验。